

Un desplazamiento anómalo en la distribución latente de puntajes del concurso de selección a licenciatura de la UNAM tras la transición al examen en línea

Jeffrey E. Bárcenas Mosqueda^{1, *}

¹*Colegio de Ciencias y Humanidades, Plantel Naucalpan,
Universidad Nacional Autónoma de México, Naucalpan, Estado de México, México*
(Dated: 21 de julio de 2026)

En 2026 la Universidad Nacional Autónoma de México (UNAM) aplicó por primera vez de forma íntegramente remota su examen de selección a licenciatura, tras cinco ciclos de aplicación presencial en sedes arrendadas. Analizamos los puntajes mínimos de admisión (*aciertos mínimos*) publicados por la Dirección General de Administración Escolar para los ciclos 2021–2026. El punto de partida metodológico es que dicho puntaje no es una medida de desempeño sino el estadístico de orden K -ésimo de una distribución latente de puntajes, censurado por un piso administrativo. Construimos un modelo jerárquico bayesiano que invierte ese estadístico hacia la media latente y separa efectos de programa y de ciclo mediante una caminata aleatoria de primer orden. Los efectos de programa se marginalizan analíticamente por la identidad de Sherman–Morrison, lo que reduce el espacio de parámetros de ~ 190 a 13 dimensiones y hace viable el muestreo con un algoritmo de ensamble afin-invariante. Estimamos un desplazamiento de 15.82 aciertos (IC 95%: [15.11, 16.54]) en la media latente de 2026 respecto de 2025, sobre un total de 120 reactivos. Una validación *leave-one-year-out* muestra que la discrepancia predictiva típica del modelo es de ± 5 aciertos y está centrada en cero para 2024 y 2025, mientras que 2026 exhibe una discrepancia de 14.96 aciertos con la totalidad del intervalo de credibilidad fuera de la banda de calibración. El resultado es robusto a variaciones de un factor dos en el único parámetro débilmente identificado del modelo. Discutimos por qué la magnitud estimada no es atribuible a un único mecanismo y delimitamos con precisión qué no puede establecerse con datos agregados.

I. INTRODUCCIÓN

El concurso de selección a licenciatura de la UNAM es uno de los procesos de evaluación educativa de mayor escala en Iberoamérica. En el ciclo 2026 se registraron 191 306 aspirantes, de los cuales 158 712 presentaron la prueba. Ese ciclo introdujo un cambio de diseño sin precedente: el examen, históricamente aplicado de manera presencial en sedes arrendadas por la institución, se aplicó íntegramente en línea desde el domicilio de cada sustentante, con navegador seguro y supervisión remota asistida por sistemas automáticos, a lo largo de una ventana de tres semanas [1].

Un cambio de esta naturaleza plantea una pregunta empírica inmediata: *¿cambió la distribución de puntajes?* La respuesta parecería estar al alcance de una comparación directa de los puntajes de corte publicados. Sostenemos que esa comparación es engañosa por dos razones, y que corregirlas modifica la magnitud estimada del fenómeno en un factor cercano a dos.

La primera razón es que el puntaje de corte no mide desempeño. Es el puntaje del último aspirante admitido, es decir, un estadístico de orden cuya posición depende conjuntamente de la oferta de lugares, del número de sustentantes y de la forma de la distribución latente de puntajes. La segunda es que en 2026 la razón de selección aumentó simultáneamente: se admitió a una fracción mayor de los sustentantes, lo que *por sí solo* presiona el corte a la baja. Que el corte haya subido pese a ello implica un desplazamiento de la distribución subyacente mayor que el observado en la superficie.

Este trabajo formaliza esa intuición. La sección II describe los datos y los criterios de inclusión; la sección III, el modelo de inversión de cuantil censurado y su implementación; la

sección IV, los resultados y su validación; y la sección V, los límites de lo que puede inferirse. Este último punto no es un apéndice de cautela: es, a nuestro juicio, la contribución más importante del artículo.

II. DATOS

La Dirección General de Administración Escolar publica, por ciclo y por programa, la oferta de lugares, el número de aspirantes registrados, el número que presentó el examen, el puntaje mínimo de admisión y el número de seleccionados. Recopilamos estas cifras para los ciclos 2021–2026, obteniendo 1 253 registros de programa-ciclo.

La unidad de análisis es el par (código de programa, modalidad): un mismo código se emplea para las modalidades abierta y a distancia, de modo que el código por sí solo no identifica unívocamente. Se identificó además un piso administrativo uniforme de 40 aciertos en las tres modalidades, por debajo del cual no se admite a ningún aspirante. Las observaciones en ese piso están censuradas por la izquierda: el corte deja de ser informativo sobre la distribución latente. Excluimos también los casos de saturación, en que prácticamente todo sustentante fue admitido, y aquellos con muy pocos sustentantes. Formalmente conservamos las observaciones que cumplen

$$c_{jt} > 40, \quad 0.01 < \frac{K_{jt}}{N_{jt}} < 0.95, \quad N_{jt} > 30, \quad (1)$$

donde c_{jt} es el puntaje de corte, K_{jt} el número de seleccionados y N_{jt} el de sustentantes del programa j en el ciclo t . Quedan 1016 observaciones (83.7% del total) sobre 180 unidades con al menos tres ciclos.

* jeffrey.barcenas@cch.unam.mx

III. MODELO

A. Inversión del cuantil

Sea X_{jt} el puntaje de un sustentante del programa j en el ciclo t , sobre 120 reactivos. Suponemos $X_{jt} \sim \mathcal{N}(\mu_{jt}, s^2)$. El procedimiento de admisión ordena a los sustentantes y admite a los K_{jt} de mayor puntaje, de modo que el corte satisface

$$P(X_{jt} \geq c_{jt}) \simeq \frac{K_{jt}}{N_{jt}} \equiv p_{jt}. \quad (2)$$

Cada registro proporciona, por tanto, un punto de la función de distribución acumulada latente. Invirtiendo,

$$\hat{\mu}_{jt} = c_{jt} - \frac{1}{2} - s z_{jt}, \quad z_{jt} = \Phi^{-1}(1 - p_{jt}), \quad (3)$$

con corrección por continuidad. La incertidumbre de $\hat{\mu}_{jt}$ proviene del error binomial en p_{jt} ; por el método delta,

$$v_{jt} \equiv \text{Var}(\hat{\mu}_{jt}) = \frac{s^2 p_{jt}(1 - p_{jt})}{N_{jt} \phi(z_{jt})^2}. \quad (4)$$

La ecuación (3) explicita el punto central del artículo: el desplazamiento latente combina el cambio del corte y el cambio de la razón de selección. Un aumento de p reduce z , de manera que un corte que sube mientras la selección se amplía implica un desplazamiento de μ estrictamente mayor que Δc .

B. Estructura jerárquica

Descomponemos la media latente en un efecto de programa y uno de ciclo,

$$\mu_{jt} = a_j + \tau_t + \eta_{jt}, \quad \eta_{jt} \sim \mathcal{N}(0, \sigma_\eta^2), \quad (5)$$

con $a_j \sim \mathcal{N}(m_{g(j)}, \sigma_a^2)$, donde $g(j)$ indexa el área de conocimiento. Los efectos de ciclo siguen una caminata aleatoria de primer orden, $\tau_t = \tau_{t-1} + \varepsilon_t$, $\varepsilon_t \sim \mathcal{N}(0, \sigma_{\text{rw}}^2)$, con $\tau_{2021} \equiv 0$ por identificabilidad. Esta elección es deliberadamente permisiva: una caminata aleatoria admite tendencias suaves y no penaliza cambios graduales, de modo que no fuerza la detección de una discontinuidad.

C. Marginalización de los efectos de programa

Con ~ 180 programas, el muestreo directo de $\{a_j\}$ es hostil para un algoritmo de ensamble. Dado que el modelo es gaussiano condicionalmente en las escalas, los a_j pueden integrarse de forma exacta. Para el programa j con n_j observaciones, sea $r_{jt} = \hat{\mu}_{jt} - \tau_t - m_{g(j)}$. Entonces

$$\mathbf{r}_j \sim \mathcal{N}(\mathbf{0}, \mathbf{D}_j + \sigma_a^2 \mathbf{1}\mathbf{1}^\top), \quad \mathbf{D}_j = \text{diag}(v_{jt} + \sigma_\eta^2). \quad (6)$$

La identidad de Sherman–Morrison [2] da la forma cuadrática y el determinante en $\mathcal{O}(n_j)$:

$$Q_j = \sum_t u_{jt} r_{jt}^2 - \frac{\sigma_a^2 (\sum_t u_{jt} r_{jt})^2}{1 + \sigma_a^2 \sum_t u_{jt}}, \quad (7)$$

$$\ln|\square_j| = -\sum_t \ln u_{jt} + \ln(1 + \sigma_a^2 \sum_t u_{jt}), \quad (8)$$

Tabla I. Efectos de ciclo. Mediana a posteriori e intervalo de credibilidad al 95%, en aciertos.

Ciclo	Mediana	IC 95%
2021	0.00	[0.00, 0.00]
2022	-1.58	[-2.28, -0.87]
2023	-0.94	[-1.64, -0.23]
2024	0.20	[-0.53, 0.91]
2025	-0.04	[-0.73, 0.68]
2026	15.79	[15.05, 16.52]

con $u_{jt} = (v_{jt} + \sigma_\eta^2)^{-1}$. Todas las sumas se evalúan de forma vectorizada. El espacio muestral se reduce a los 13 hiperparámetros $(\tau_{2022..2026}, m_{1..4}, \ln s, \ln \sigma_a, \ln \sigma_\eta, \ln \sigma_{\text{rw}})$.

D. Distribuciones a priori

Adoptamos $\sigma_a, \sigma_\eta, \sigma_{\text{rw}}$ semi-normales, $m_g \sim \mathcal{N}(60, 30^2)$ y, para la desviación estándar latente, $\ln s \sim \mathcal{N}(\ln 17, 0.25^2)$. Este último es el único prior con consecuencias sustantivas, porque s fija la escala de la inversión (3). Es también el parámetro cuya identificación resulta más débil: proviene únicamente de la exigencia de que $c_{jt} - s z_{jt}$ admita una descomposición aditiva parsimoniosa. La sección IV D documenta que la conclusión principal es insensible a esta elección.

E. Cómputo

El muestreo se realizó con el algoritmo de ensamble afín-invariante de Goodman y Weare [3], en la implementación emcee [4], con 80 caminantes y una mezcla de movimientos diferenciales (80% DEMove, 20% DESnookerMove). Dos decisiones fueron necesarias para obtener mezcla aceptable. Primero, el centrado de z_{jt} respecto de su media muestral, que decorrela s de los niveles m_g ; sin él, el tiempo de autocorrelación integrado excede los 300 pasos. Segundo, una inicialización con dispersión ajustada por bloque a la escala de cada parámetro: los movimientos diferenciales dependen de la diversidad del ensamble, y una bola isotrópica pequeña produce exploración deficiente en las direcciones de nivel. Con ambos ajustes, $\tau_{\text{int}} \leq 89$ pasos sobre cadenas de 8 000, con tasa de aceptación de 0.24.

IV. RESULTADOS

A. Trayectoria latente

La figura 1 y la tabla I presentan los efectos de ciclo. El periodo 2021–2025 es notablemente estable: todas las medianas caen en el intervalo $[-1.6, 0.2]$ aciertos, con intervalos de credibilidad que rara vez exceden ± 1 acierto. El ciclo 2026 rompe ese patrón con un valor de 15.79 aciertos.




Figura 1. Efecto latente de ciclo τ_t , en aciertos sobre 120, con 2021 como referencia. Bandas: intervalos de credibilidad al 68% y 95%. La estabilidad del periodo presencial contrasta con el salto de 2026.

Tabla II. Validación *leave-one-year-out*. n es el número de programas evaluados; $\bar{D}$ la discrepancia media en aciertos.

Ciclo	n	$\bar{D}$	IC 95%	RECM
2024	152	0.98	[-4.27, 5.82]	4.33
2025	164	-0.57	[-4.98, 3.64]	4.46
2026	160	14.96	[11.61, 18.31]	16.83

La diferencia entre ciclos consecutivos 2026–2025 es de 15.82 aciertos, con intervalo [15.11, 16.54] y $P(\Delta\tau > 0) > 0.9999$. Conviene contrastar esta cifra con el aumento crudo del puntaje de corte, de 9.2 aciertos en promedio sobre los programas pareados. La discrepancia entre ambas —un factor de 1.7— es exactamente el efecto anticipado en la introducción: la razón media de selección pasó de 0.35 a 0.42, y esa ampliación de la admisión enmascara parte del desplazamiento subyacente. La desviación estándar latente estimada es $s = 21.1$ aciertos ([20.2, 21.9]), de modo que el desplazamiento equivale a aproximadamente 0.75 desviaciones estándar.

B. Validación *leave-one-year-out*

Que un salto sea grande respecto de la serie previa no basta: hay que saber cuánto se equivoca el modelo al predecir un ciclo que no ha visto. Ajustamos el modelo usando únicamente los ciclos anteriores a un ciclo T dado, extrapolamos la caminata aleatoria un paso, obtenemos la posterior condicional de cada a_j y predecimos el corte *manteniendo fija la razón de selección observada en T* . La discrepancia $D_{jT} = c_{jT}^{\text{obs}} - c_{jT}^{\text{pred}}$ mide entonces el desplazamiento distribucional no anticipado, limpio de cambios en oferta y demanda.

Los resultados (figura 2, tabla II) establecen la banda de calibración. Para 2024 y 2025 la discrepancia media es compatible con cero y el error cuadrático medio ronda los 4.4 aciertos. Para 2026 la discrepancia media es 14.96 aciertos, con el extremo inferior del intervalo al 95% en 11.61, muy por encima del extremo superior de cualquiera de los ciclos de calibración.




Figura 2. Validación *leave-one-year-out*. Distribución a posteriori de la discrepancia predictiva media para cada ciclo excluido. Los ciclos presenciales 2024 y 2025 se centran en cero; 2026 se separa por completo de la banda de calibración.




Figura 3. Discrepancia mediana por área de conocimiento en 2026. Las líneas indican el rango intercuartil entre programas. La atenuación del área IV es atribuible en parte a censura por el piso administrativo.

El error cuadrático medio se cuadruplica. En términos operativos: el modelo predice un ciclo presencial no observado con un error típico de ± 5 aciertos, y falla en 2026 por un margen tres veces mayor y sistemático en signo.

C. Heterogeneidad

La discrepancia de 2026 no es uniforme (tabla III, figura 3). Las áreas I, II y III presentan valores medianos entre 16.7 y 18.2 aciertos, mientras que el área IV se sitúa en 7.6. Interpretamos esta diferencia con cautela: los programas del área IV concentran los cortes más bajos y por tanto la mayor proximidad al piso administrativo, donde el estadístico de orden pierde sensibilidad. Parte de la atenuación es, con alta probabilidad, un artefacto de censura y no un efecto sustantivo.

Por modalidad, en cambio, la homogeneidad es llamativa: escolarizado (15.3), abierta (14.4) y a distancia (12.5) presentan discrepancias comparables. Este resultado corrige de manera directa una lectura descriptiva ingenua: sobre los puntajes de corte sin modelar, las modalidades abierta y a distancia parecen saltar casi el doble que la escolarizada. Esa diferencia aparente se disuelve al condicionar sobre las razones de selección, y era un artefacto de composición.

Tabla III. Discrepancia de 2026 por área de conocimiento y por modalidad de estudio, en aciertos.

Estrato	n	Media	Mediana
I. Físico-Matemáticas	41	15.78	16.65
II. Biológicas y Salud	39	17.47	17.88
III. Sociales	49	16.25	18.24
IV. Humanidades y Artes	31	8.81	7.61
Abierta	20	14.37	15.27
Escolarizado	127	15.34	16.35
Suayed	13	12.45	12.09

Tabla IV. Análisis de sensibilidad: $\Delta\tau_{2026-2025}$ con la desviación estándar latente s fijada.

s (aciertos)	$\Delta\tau$	IC 95%
13	14.74	[13.88, 15.59]
17	15.29	[14.51, 16.06]
21	15.82	[15.09, 16.57]
25	16.29	[15.54, 17.04]

D. Sensibilidad al prior sobre s

La tabla IV reporta $\Delta\tau_{2026-2025}$ fijando s en valores que abarcan un factor de dos. La estimación varía entre 14.7 y 16.3 aciertos: el parámetro peor identificado del modelo no compromete la conclusión. Cabe señalar además que, con prior centrado en 17, la posterior se desplaza a 21.1, lo que indica que s recibe información empírica genuina a través de la estructura aditiva.

V. QUÉ NO PUEDE CONCLUIRSE

El desplazamiento estimado es grande, robusto y está bien calibrado contra el comportamiento histórico del modelo. Nada de ello autoriza a atribuirlo a un mecanismo particular, y conviene ser explícito sobre por qué.

El diseño carece de grupo de control contemporáneo. La totalidad de los sustentantes de 2026 recibió el mismo tratamiento, de modo que el estimando $\Delta\tau$ agrega *todo* lo que cambió en ese ciclo. Al menos cuatro mecanismos son compatibles con lo observado y este diseño no los distingue.

(i) *Reducción de fricción logística*. Presentar desde el domicilio elimina traslados y la incertidumbre asociada a sedes desconocidas. El mecanismo es real y benévolo. Observamos, sin embargo, que la tasa de no presentación en la modalidad escolarizada *aumentó* de 0.171 a 0.184, lo que debilita la versión fuerte de esta explicación.

(ii) *Cambio de instrumento*. Una ventana de aplicación de tres semanas exige múltiples formas del examen. Cualquier diferencia de calibración entre bancos de reactivos se confunde de manera perfecta con la modalidad.

(iii) *Integridad del proceso*. La propia institución reportó la

cancelación del proceso de aproximadamente el 2% de los aspirantes por conductas contrarias a la convocatoria [1]. Una ventana prolongada crea, en principio, condiciones para la filtración de reactivos entre jornadas.

(iv) *Composición de la población*. La participación y la oferta de lugares cambiaron simultáneamente, alterando quién se presenta y con qué nivel de preparación.

Ninguna partición de $\Delta\tau$ entre estos cuatro canales es identificable con datos agregados de programa-ciclo. Señalamos, no obstante, un diseño que sí tendría poder discriminante y que requiere únicamente información pública adicional: la asignación de cada programa a una jornada específica dentro de la ventana de tres semanas. Bajo el mecanismo (i), $\Delta\tau$ debe ser homogéneo respecto de la fecha de aplicación; bajo el mecanismo (iii), debe crecer con ella. Se trata de un contraste de dosis-respuesta con grupo de comparación interno al ciclo 2026, inmune a la mayor parte de los factores de confusión enumerados. Lo dejamos como continuación natural de este trabajo.

Una limitación adicional merece énfasis. Todas las inferencias operan en el nivel de programa-ciclo. Trasladarlas a afirmaciones sobre sustentantes individuales constituiría una falacia ecológica. En particular, este análisis no sustenta ninguna afirmación sobre la conducta de ningún aspirante, ni sobre la validez de ninguna admisión concreta.

VI. CONCLUSIONES

Tratar el puntaje de corte como lo que es, un estadístico de orden censurado y no como una medida de desempeño modifica de manera sustantiva las conclusiones. El desplazamiento de la distribución latente de puntajes en 2026 es de 15.82 aciertos sobre 120, cerca de 0.75 desviaciones estándar latentes, frente a un aumento aparente de 9.2 aciertos en los cortes publicados. Una validación *leave-one-year-out* sitúa ese valor muy fuera de la banda de error predictivo del modelo, calibrada en ± 5 aciertos sobre los ciclos presenciales. El resultado resiste variaciones de un factor dos en el único parámetro débilmente identificado.

Metodológicamente, el trabajo ilustra que la marginalización analítica de efectos aleatorios gaussianos permite abordar modelos jerárquicos de varios cientos de parámetros con muestreadores de ensamble, que de otro modo resultarían inadecuados.

Sustantivamente, la conclusión defendible es que el proceso de medición de 2026 no es comparable con el de los ciclos precedentes. Determinar *por qué* exige información que este conjunto de datos no contiene.

AGRADECIMIENTOS

El autor agradece a la Dirección General de Administración Escolar de la UNAM la publicación abierta de las cifras del concurso de selección, sin la cual este análisis no sería posible. El diseño del estudio, las decisiones de modelación, la inter-

pretación de los resultados y la responsabilidad por su contenido corresponden íntegramente al autor.

-
- [1] *La UNAM realiza la aplicación en línea de su examen de admisión para el ingreso a licenciatura 2026*, Gaceta UNAM (25 de mayo de 2026).
 - [2] W. W. Hager, *Updating the inverse of a matrix*, SIAM Rev. **31**, 221 (1989).
 - [3] J. Goodman and J. Weare, *Ensemble samplers with affine invariance*, Commun. Appl. Math. Comput. Sci. **5**, 65 (2010).
 - [4] D. Foreman-Mackey, D. W. Hogg, D. Lang, and J. Goodman, *emcee: The MCMC hammer*, Publ. Astron. Soc. Pac. **125**, 306 (2013).
 - [5] A. Gelman, J. B. Carlin, H. S. Stern, D. B. Dunson, A. Vehtari, and D. B. Rubin, *Bayesian Data Analysis*, 3rd ed. (CRC Press, Boca Raton, 2013).
 - [6] A. Vehtari, A. Gelman, and J. Gabry, *Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC*, Stat. Comput. **27**, 1413 (2017).
 - [7] M. Betancourt and M. Girolami, *Hamiltonian Monte Carlo for hierarchical models*, arXiv:1312.0906 (2013).
 - [8] P. W. Holland, *Statistics and causal inference*, J. Am. Stat. Assoc. **81**, 945 (1986).
 - [9] D. B. Rubin, *Estimating causal effects of treatments in randomized and nonrandomized studies*, J. Educ. Psychol. **66**, 688 (1974).